

Анализ временных рядов.

Лекция 4

SARIMAX

Костромина Алина

1.12.2025

Что сегодня в программе?

1. Где ETS модели не справляются — зачем нам SARIMA(X)?
2. Предпосылки. Еще раз говорим о стационарности.
3. ARMA модель. ACF / PACF.
4. Добавляем интегрирование — ARIMA.
5. Добавляем сезонное интегрирование — SARIMA.
6. Добавляем внешние признаки — SARIMAX.

Две парадигмы: компоненты vs автокорреляции

ETS

ARIMA

Моделируем
компоненты

Моделируем
автокорреляции

Существует
таксономия моделей

Нестационарность в
компонентах +
стационарность в ошибках

Легкая
интерпретация,
хорошие
краткосрочные
прогнозы

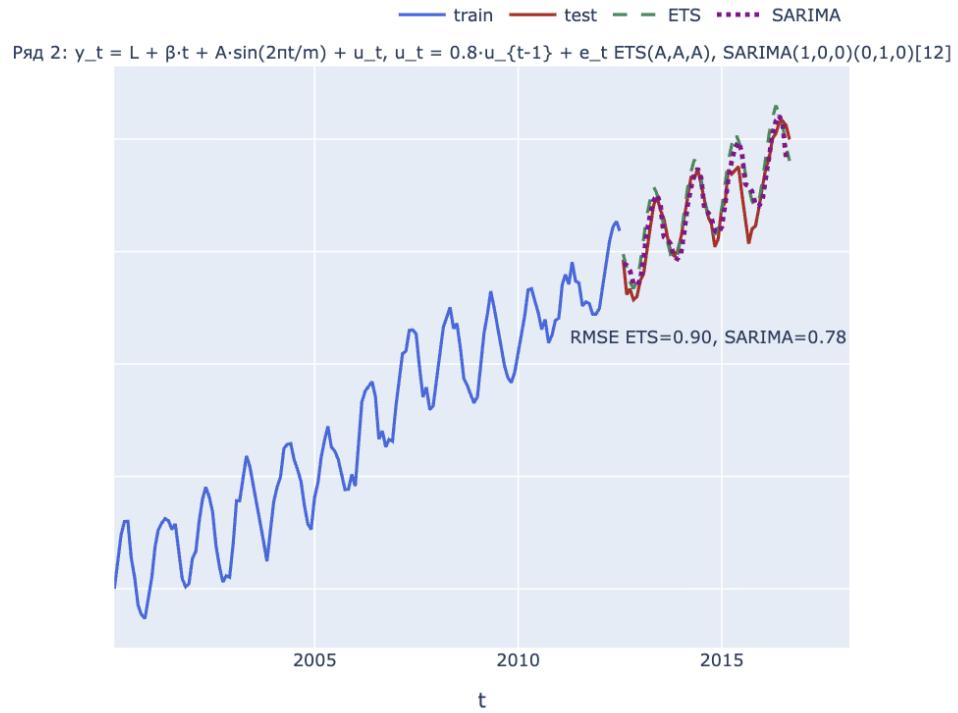
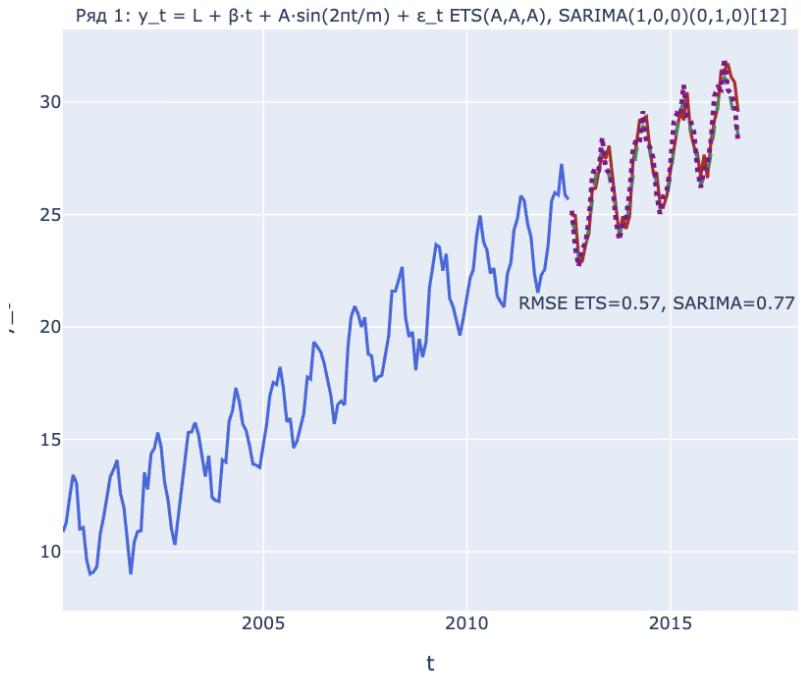
Есть модели,
которые можно
описать двумя
способами

Потенциально
неограниченное
множество моделей

Нестационарность в
интегрировании и
сезонности +
стационарность в ARMA

Сложные структурные
зависимости,
хорошие
долгосрочные
прогнозы

ETS vs. SARIMA на практике



ARIMA. Предпосылка — стационарность

AR(p) (Autoregression) - модель авторегрессии порядка p .

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

MA(q) (Moving average) - модель скользящего среднего порядка q :

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

Если объединим две модели, то получим **ARMA(p, q)** модель:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

ARIMA(p, d, q) является расширением модели ARMA на нестационарные ряды:

$$\Delta^d y_i = c + \sum_{j=1}^p \phi_j \Delta^d y_{i-j} + \varepsilon_i + \sum_{j=1}^q \theta_j \varepsilon_{i-j}$$

где d - порядок дифференцирования для приведения ряда к стационарному

Теоретическая мотивация: любой стационарный в широком смысле процесс можно аппроксимировать с заданной точностью, выбрав необходимые p и q .

Почему стационарность важна?

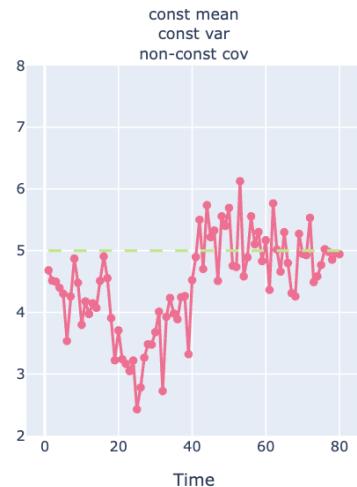
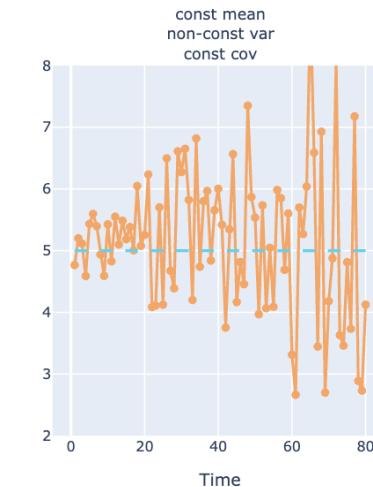
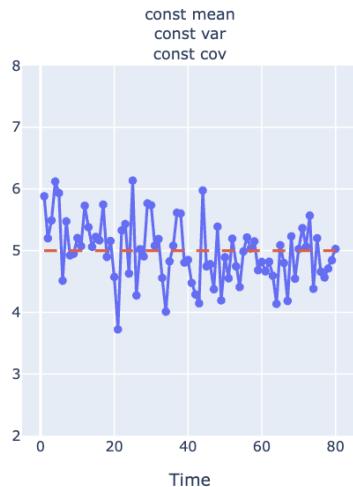
1. Хотим «хорошие» прогнозы и оцениваемые параметры, которые стабильны и адекватны и имеют удобные статистические свойства (можно проверять гипотезы, считать доверительные / прогнозные интервалы и т. д.).
2. Без стационарности не сможем подобрать гиперпараметры модели (p, q) — разберем позже на примерах.
3. Даже в ETS-модели ошибки (инновации) предполагаются стационарными (i.i.d шум) — так что это не новая вещь.

Повторим разговор про стационарность

В узком смысле (сильная стационарность) — временной ряд $y_1 \dots, y_t$ стационарен, если для любого s совместное распределение $y_1 \dots, y_{t+s}$ не зависит от t .

В широком смысле (слабая стационарность) — временной ряд $y_1 \dots, y_t$ стационарен, если:

1. Существуют конечные матожидание $m(t)$ и дисперсия $v(t)$ в каждой точке $t \in T$.
2. $m(t) = \text{const. } v(t) = \text{const.}$
3. Автоковариационная функция зависит от лага τ и не зависит от t — $\text{Cov}(y_t, y_{t+\tau}) = \gamma(\tau)$.



Парочка упражнений

Упр. 1 — Стационарен ли ряд ...?

$y_t = \mu + \varepsilon_t$, где μ — константа, а $\{\varepsilon_t\}$ — белый шум:

$$E[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2, \quad \text{Cov}(\varepsilon_t, \varepsilon_{t+h}) = 0 \text{ при } h \neq 0.$$

Упр. 2 — Стационарен ли ряд ...?

$y_t = y_{t-1} + c + \varepsilon_t, \quad t \geq 1, \quad y_0 = 0$, где c — константа, а $\{\varepsilon_t\}$ — белый шум:

$$E[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2, \quad \text{Cov}(\varepsilon_t, \varepsilon_{t+h}) = 0 \text{ при } h \neq 0.$$

Парочка упражнений

Упр. 1 — Стационарен ли ряд **ДА**?

$y_t = \mu + \varepsilon_t$, где μ — константа, а $\{\varepsilon_t\}$ — белый шум:

$$E[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2, \quad \text{Cov}(\varepsilon_t, \varepsilon_{t+h}) = 0 \text{ при } h \neq 0.$$

Решение

$$1. E[y_t] = E[\mu + \varepsilon_t] = \mu + E[\varepsilon_t] = \mu + 0 = \mu = \text{const.}$$

$$2. \text{Var}(y_t) = \text{Var}(\mu + \varepsilon_t) = \text{Var}(\varepsilon_t) = \sigma^2 = \text{const.}$$

$$\begin{aligned} 3. \text{Cov}(y_t, y_{t+h}) &= \text{Cov}(\mu + \varepsilon_t, \mu + \varepsilon_{t+h}) = \text{Cov}(\mu, \mu) + \text{Cov}(\mu, \varepsilon_{t+h}) \\ &= \text{Cov}(\varepsilon_t, \varepsilon_{t+h}) \end{aligned}$$

$$\text{Cov}(\varepsilon_t, \varepsilon_{t+h}) = \begin{cases} \sigma^2, & h = 0, \\ 0, & h \neq 0. \end{cases}$$

Зависит только от лага h , а не от времени t .

Вывод.

Ряд $y_t = \mu + \varepsilon_t$ **стационарен в слабом смысле**.

Упр. 2 — Стационарен ли ряд **НЕТ**?

$y_t = y_{t-1} + c + \varepsilon_t$, $t \geq 1$, $y_0 = 0$, где c — константа, а $\{\varepsilon_t\}$ — белый шум:

$$E[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2, \quad \text{Cov}(\varepsilon_t, \varepsilon_{t+h}) = 0 \text{ при } h \neq 0.$$

Решение

$$y_1 = y_0 + c + \varepsilon_1 = c + \varepsilon_1,$$

$$y_2 = y_1 + c + \varepsilon_2 = 2c + \varepsilon_1 + \varepsilon_2,$$

$$y_3 = y_2 + c + \varepsilon_3 = 3c + \varepsilon_1 + \varepsilon_2 + \varepsilon_3.$$

Отсюда по индукции: $y_t = tc + \varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t$.

$$\begin{aligned} 1. E[y_t] &= E[tc + \varepsilon_1 + \cdots + \varepsilon_t] \\ &= tc + E[\varepsilon_1] + \cdots + E[\varepsilon_t] \\ &= tc. \end{aligned}$$

$E[y_t] = tc$ зависит от времени t .

```
# Стационарный ряд: константа + белый шум  
mu = 5.0  
sigma = 1.0  
eps_stat = np.random.normal(loc=0.0, scale=sigma, size=n)  
y_stat = mu + eps_stat
```

Стаци. ряд

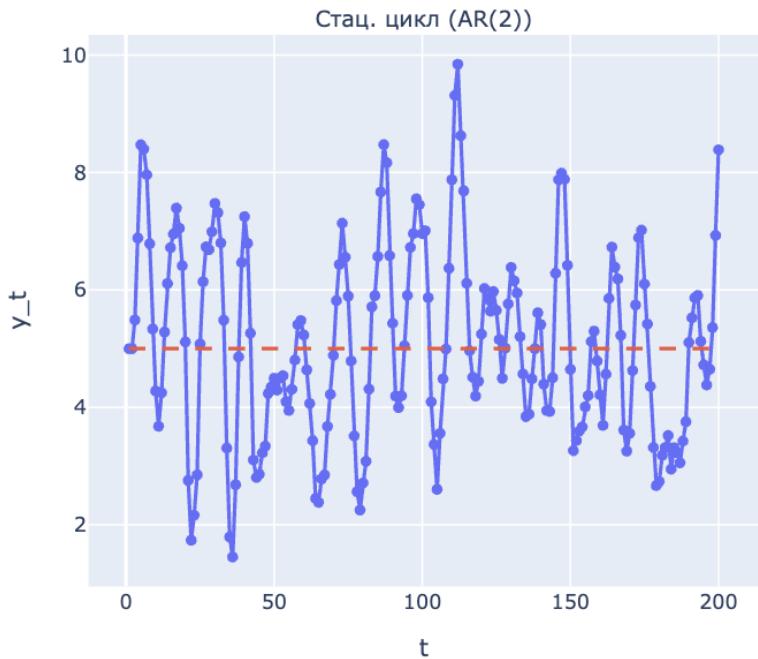


```
# Нестационарный ряд: случайное блуждание с дрейфом  
c = 0.2  
eps_ns = np.random.normal(loc=0.0, scale=1.0, size=n)  
y_ns_raw = np.cumsum(c + eps_ns)
```

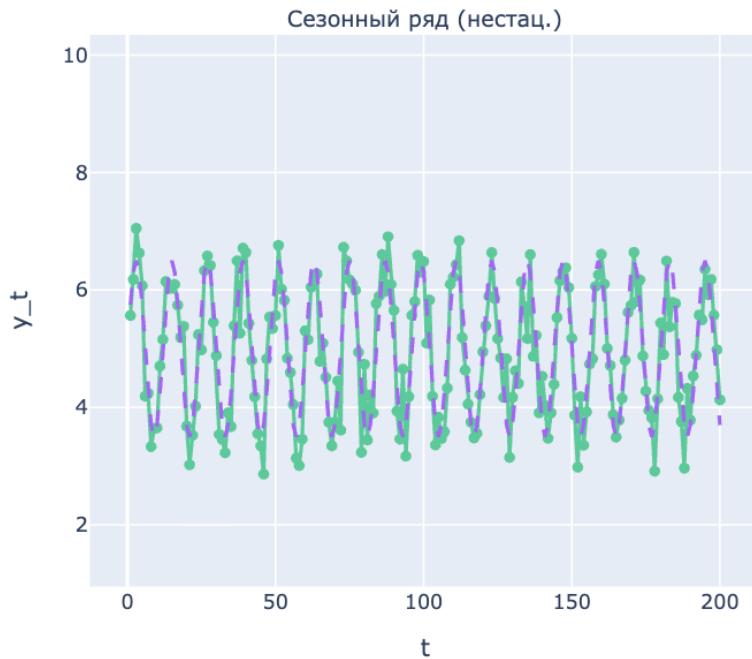
Нестац. ряд



Примечание 1: Цикл vs. сезонность



$$y_t = \mu + u_t, \\ u_t = \varphi_1 u_{t-1} + \varphi_2 u_{t-2} + \varepsilon_t, \\ \varphi_1 = 2r \cos w, \quad \varphi_2 = -r^2, \\ r < 1, \quad w = 2\pi/20$$

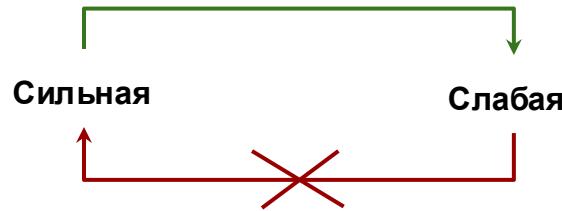


$$y_t = s_t + \varepsilon_t, \quad s_{t+m} = s_t, \quad t = 1, 2, \dots$$

Примечание 2: Сильная vs. слабая стационарности

Если существуют конечные $E(y_t)$ и $Var(y_t)$.

Совместные
распределения
не меняются



mean/variance/autocov
не меняются

Тесты на стационарность

Aspect	KPSS Test	Dickey-Fuller Test
Hypothesis Tested	Null: The series is stationary.	Null: The series is non-stationary.
Alternative Hypothesis	The series is non-stationary.	The series is stationary.
Sensitivity	Detects trend stationarity issues.	Detects unit root (random walk) stationarity.
Approach	Tests for stationarity by modeling residuals.	Checks for unit roots in the series.

ADF — оцениваем регрессию на приrostы и смотрим статистику при y_{t-1} (тест на единичный корень).

KPSS — суммируем остатки от регрессии на детерминированные компоненты (константа + тренд) и смотрим, насколько «уносит» частичные суммы от нуля (дисперсия == 0?).

Тесты на стационарность

ADF

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \phi_i \Delta y_{t-i} + \varepsilon_t$$

$H_0: \gamma = 0$ (ряд нестационарен)

KPSS

$$y_t = \alpha + \beta t + r_t + \varepsilon_t$$
$$r_t = r_{t-1} + u_t, \quad u_t \sim i.i.d(0, \sigma_u^2)$$

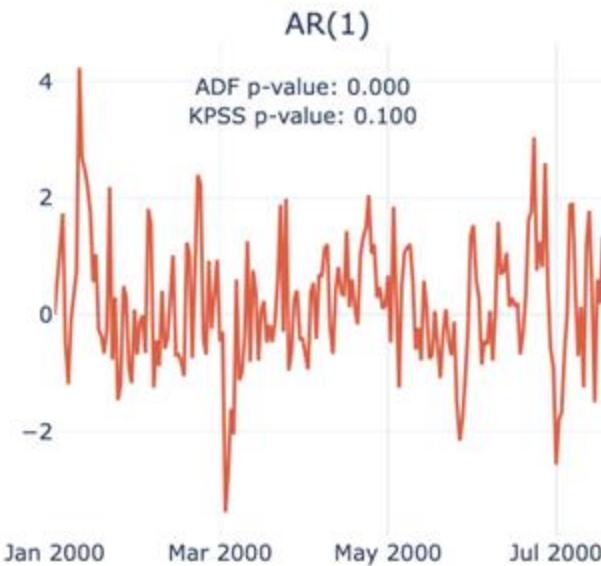
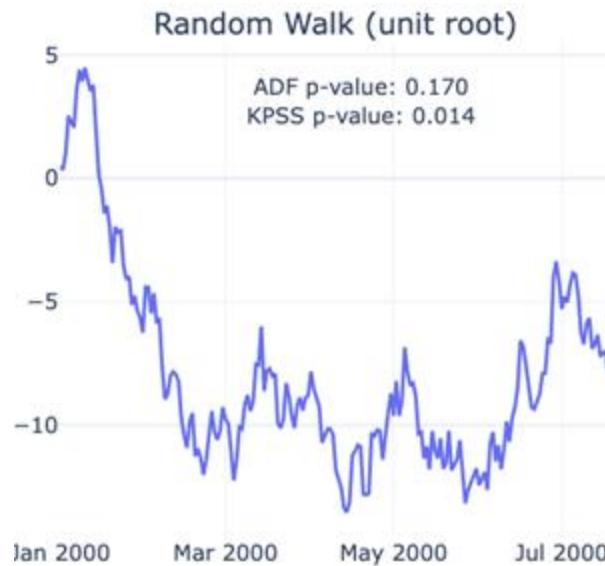
$H_0: \sigma_u^2 = 0$ (ряд стационарен)

остатки $y_t = \alpha + \beta t$ (т. к. мы под H_0)

ADF — оцениваем регрессию на приrostы и смотрим статистику при y_{t-1} (тест на единичный корень).

KPSS — суммируем остатки от регрессии на детерминированные компоненты (константа + тренд) и смотрим, насколько «уносит» частичные суммы от нуля (дисперсия == 0?).

Тесты на стационарность



Вопросы?

Определение коэффициентов вручную — ACF, PACF

ACF $\rho(k)$: насколько в среднем похожи значения ряда на расстоянии k шагов.

$$\rho(k) = \text{Corr}(x_t; x_{t+k}) = \frac{\text{Cov}(x_t, x_{t+k})}{\sqrt{D(x_t) \cdot D(x_{t+k})}} = \frac{\gamma(k)}{\sqrt{\gamma(0) \cdot \gamma(0)}} = \frac{\gamma(k)}{\gamma(0)}, \quad k \in Z$$

$$\hat{\rho}(k) = \frac{\sum_{t=1}^{T-k} (x_t - \bar{x})(x_{t+k} - \bar{x})}{\sum_{t=1}^T (x_t - \bar{x})}, \quad \bar{x} = \frac{1}{T} \sum_{t=1}^T x_t$$

Определение коэффициентов вручную — ACF, PACF

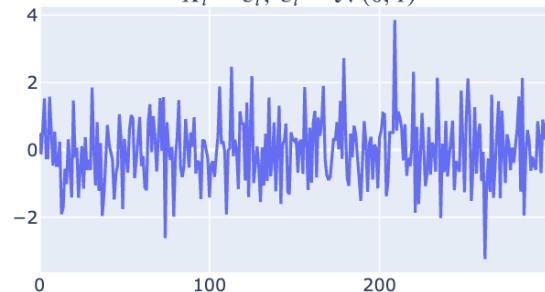
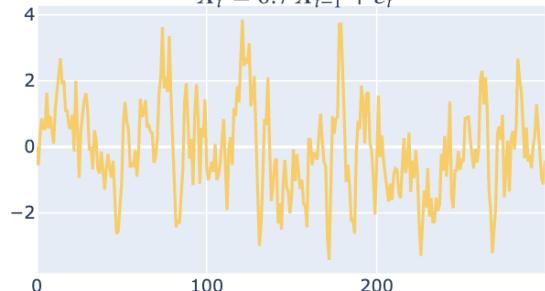
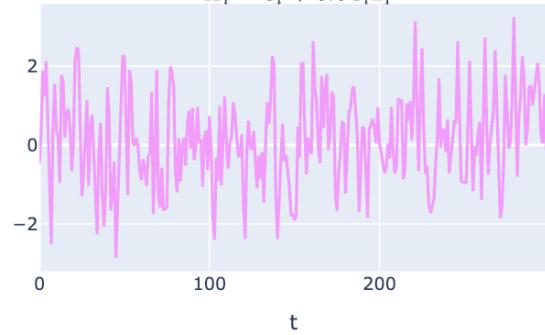
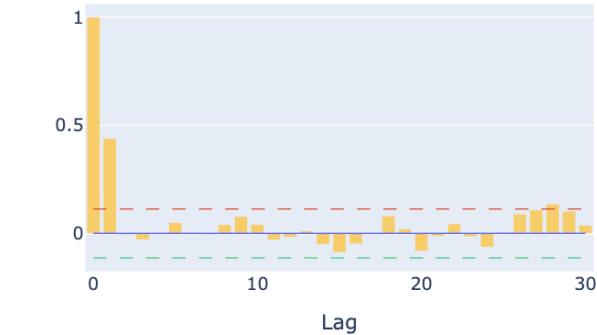
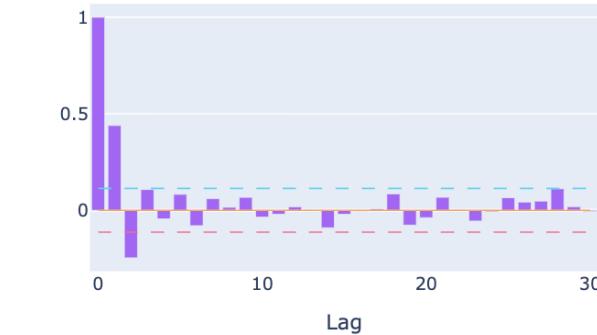
PACF $\rho_{PACF(k)}$: есть ли линейная информация на лаге k , которая не объясняется влиянием промежуточных лагов $x_{t+1}, \dots, x_{t+k-1}$.

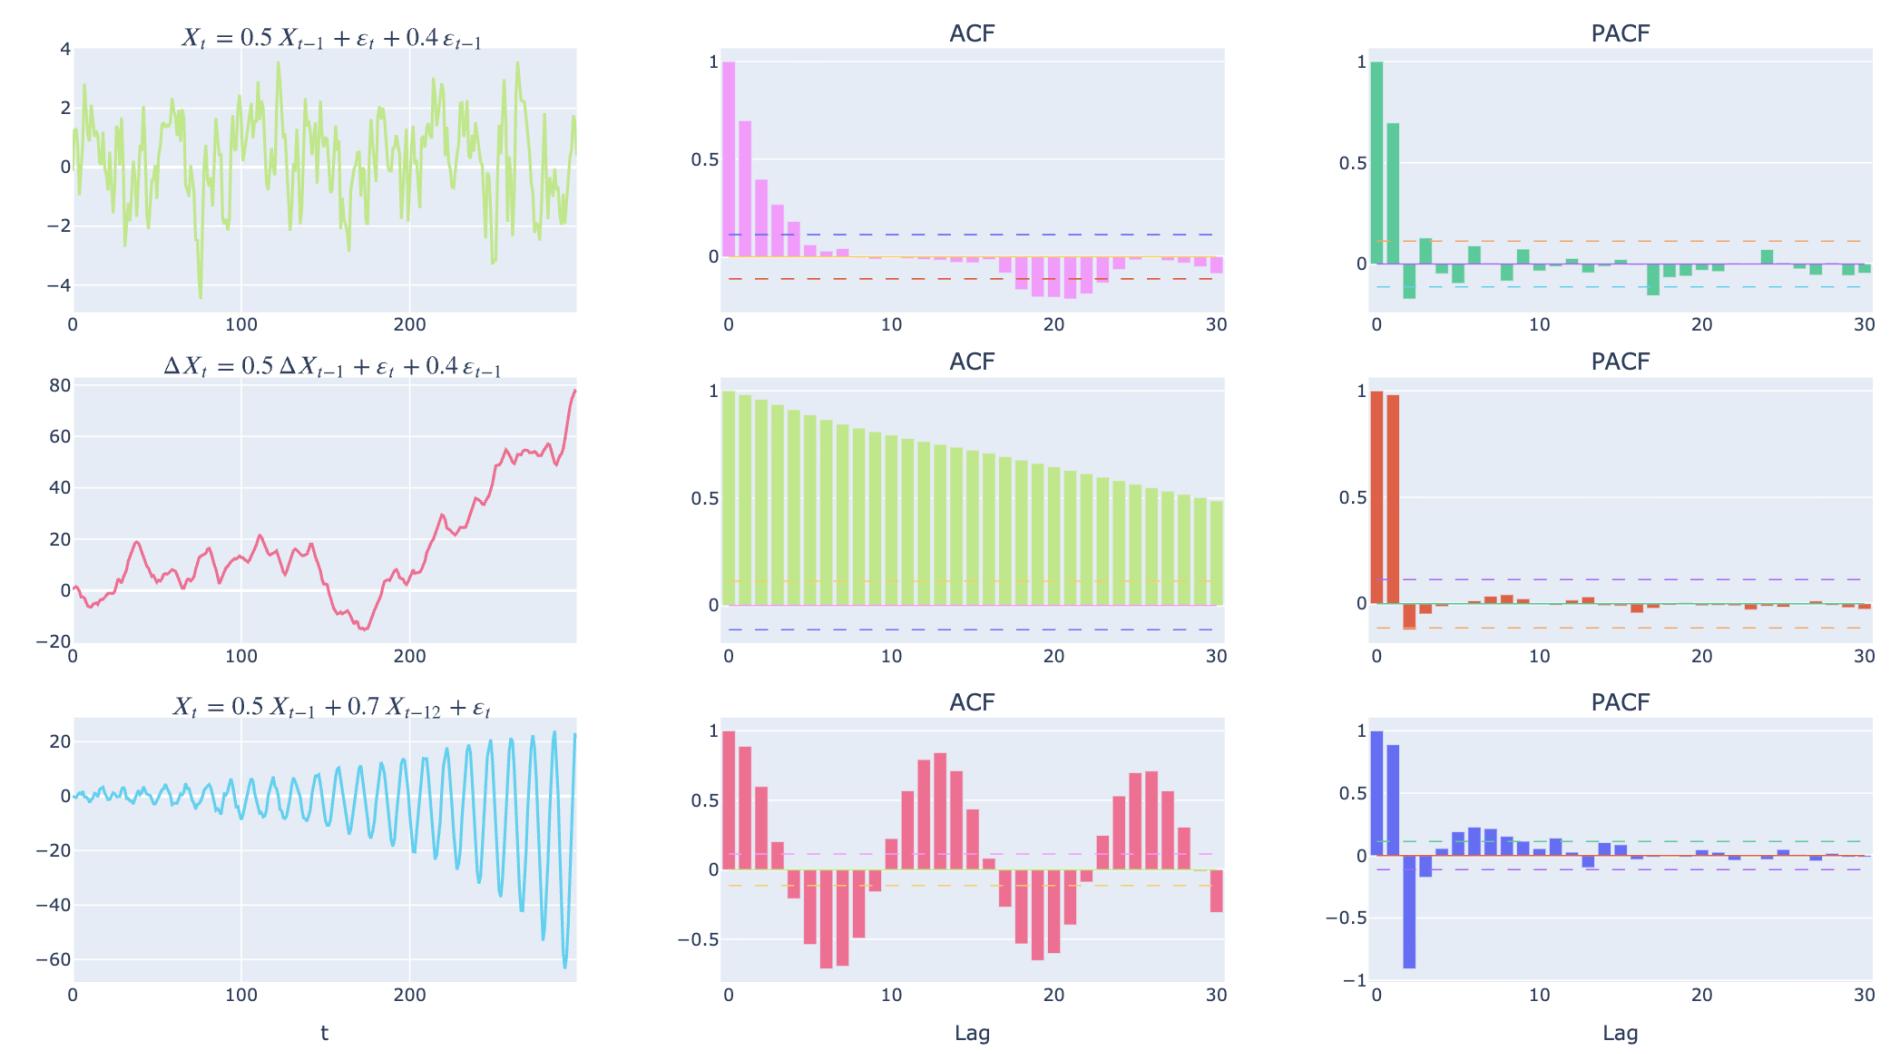
$$\rho_{PACF}(k) = \text{Corr}(x_t - \hat{x}_t; x_{t+k} - \hat{x}_{t+k}),$$

$$\hat{x}_t = \beta_1^{(1)} x_{t+1} + \dots + \beta_{k-1}^{(1)} x_{t+k-1}, \quad \hat{x}_{t+k} = \beta_1^{(2)} x_{t+1} + \dots + \beta_{k-1}^{(2)} x_{t+k-1}$$

Коэффициенты минимизируют MSE предсказаний x_t и x_{t+k}

Сначала «вычитаем» влияние промежуточных лагов из обеих переменных, а потом смотрим, насколько сильно связаны очищенные остатки.

$X_t = \varepsilon_t, \varepsilon_t \sim \mathcal{N}(0, 1)$  ACF  $PACF$  $X_t = 0.7 X_{t-1} + \varepsilon_t$  ACF  $PACF$  $X_t = \varepsilon_t + 0.6 \varepsilon_{t-1}$  ACF  $PACF$ 



ARIMA

Как подбирать гиперпараметры:
https://docs.google.com/document/d/1wVsBkRIZbHdPMQIbUoXdznrmxkSZNEVFLq9D_OzCldA/edit?usp=sharing

AR(p) (Autoregression) - модель авторегрессии порядка p .

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

Если объединим две модели, то получим **ARMA(p, q)** модель:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

Теоретическая мотивация: любой стационарный в широком смысле процесс можно аппроксимировать с заданной точностью, выбрав необходимые p и q .

MA(q) (Moving average) - модель скользящего среднего порядка q :

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

ARIMA(p, d, q) является расширением модели ARMA на нестационарные ряды:

$$\Delta^d y_i = c + \sum_{j=1}^p \phi_j \Delta^d y_{i-j} + \varepsilon_i + \sum_{j=1}^q \theta_j \varepsilon_{i-j}$$

где d - порядок дифференцирования для приведения ряда к стационарному

Как строится прогноз?

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

Пусть известны значения ряда y_t и возмущения ε_t до момента времени T включительно, а также получены веса $(\phi_i, i = \overline{1, p}, \theta_j, j = \overline{1, q})$ модели ARMA(p,q).

Выражение для y_{T+1} в рамках модели:

$$y_{T+1} = c + \sum_{i=1}^p \phi_i y_{T+1-i} + \varepsilon_{T+1} + \sum_{j=1}^q \theta_j \varepsilon_{T+1-j}.$$

Неизвестно, $E(\varepsilon_{T+1}) = 0$

$$\text{Cov}(\varepsilon_{T+1}, y_t) = 0, t \leq T$$

Выражение для y_{T+2} в рамках модели:

$$y_{T+2} = c + \sum_{i=1}^p \phi_i y_{T+2-i} + \varepsilon_{T+2} + \sum_{j=1}^q \theta_j \varepsilon_{T+2-j}.$$

Неизвестно,

$$E(\varepsilon_{T+1}) = 0$$

$$E(\varepsilon_{T+2}) = 0$$

$$E(y_{T+1}) = \hat{y}_{T+1}$$

- Неизвестные в AR части заменяют на прогнозы
- Неизвестные в MA части зануляем

SARIMA

$$y_t = c + \sum_{n=1}^p \alpha_n y_{t-n} + \sum_{n=1}^q \theta_n \epsilon_{t-n} + \sum_{n=1}^P \phi_n y_{t-sn} + \sum_{n=1}^Q \eta_n \epsilon_{t-sn} + \epsilon_t$$

SARIMA(p, d, q)(P, D, Q, s) - расширение модели

ARIMA для учета сезонности:

- s - период сезонности
- P - порядок сезонной AR части
- D - порядок сезонного дифференцирования ряда
- Q - порядок сезонной MA части

SARIMAX

$$d_t = c + \sum_{n=1}^p \alpha_n d_{t-n} + \sum_{n=1}^q \theta_n \epsilon_{t-n} + \sum_{n=1}^r \beta_n x_{n_t} + \sum_{n=1}^P \phi_n d_{t-sn} + \sum_{n=1}^Q \eta_n \epsilon_{t-sn} + \epsilon_t$$

SARIMAX(p, d, q)(P, D, Q, s):

- Работает с нестационарными рядами
- Учитывает дополнительные факторы
- Моделирует сезонные паттерны

Примечание: стационарность и инвертируемость

AR(p) (Autoregression) - модель авторегрессии порядка p :

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

Говорят, что AR-часть стационарна, если все корни уравнения $\Phi(z) = 0$ лежат **вне единичного круга**: $|z| > 1$.

Существует и сходится **MA(∞)**-представление:

$$y_t = \mu + \sum_{k=0}^{\infty} \psi_k \varepsilon_{t-k}, \sum_{k=0}^{\infty} |\psi_k| < \infty.$$

MA(q) (Moving average) - модель скользящего среднего порядка q :

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

Говорят, что MA-часть инвертируема, если все корни уравнения $\Theta(z) = 0$ лежат **вне единичного круга**: $|z| > 1$.

Существует и сходится **AR(∞)**-представление:

$$\varepsilon_t = \sum_{k=0}^{\infty} \pi_k y_{t-k}.$$

Примечание: стационарность и инвертируемость

$$y_t = \varphi y_{t-1} + \varepsilon_t.$$

$$\begin{aligned} y_t &= \varphi y_{t-1} + \varepsilon_t \\ &= \varphi(\varphi y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \\ &= \varphi^2 y_{t-2} + \varphi \varepsilon_{t-1} + \varepsilon_t \\ &\quad \dots \\ &= \varphi^k y_{t-k} + \sum_{j=0}^{k-1} \varphi^j \varepsilon_{t-j}. \end{aligned}$$

Если $|\varphi| < 1$, то при $k \rightarrow \infty$ $\varphi^k y_{t-k} \rightarrow 0$,

$$y_t = \sum_{j=0}^{\infty} \varphi^j \varepsilon_{t-j}.$$

Получили MA(∞)-представление для y_t .

$$y_t = \varepsilon_t + \theta \varepsilon_{t-1}.$$

$$y_t = (1 + \theta L) \varepsilon_t.$$

$$\varepsilon_t = (1 + \theta L)^{-1} y_t.$$

$$(1 + \theta L)^{-1} = 1 - \theta L + \theta^2 L^2 - \theta^3 L^3 + \dots$$

Этот ряд сходится только при $|\theta| < 1$.

$$\varepsilon_t = y_t - \theta y_{t-1} + \theta^2 y_{t-2} - \theta^3 y_{t-3} + \dots$$

Получили AR(∞)-представление для ε_t .

$$S = \frac{b_1}{1 - q}$$

Вопросы?

Что почитать?

- Р. Хайдман, Дж. Атанасопулос — Прогнозирование: принципы и практика, гл. 9 (стр. 272-327) (рус.).
 - <https://education.yandex.ru/handbook/ml/article/modeli-vida-arima> — учебник ШАД (глава 10.4) (рус.).
 - <https://mlgu.ru/909> — SARIMA в Python (рус.).
-
- <https://www.statsmodels.org/stable/generated/statsmodels.tsa.arima.model.ARIMA.html> — ARIMA в Python (англ.).
 - <https://nixtlaverse.nixtla.io/statsforecast/docs/models/autoarima.html> — AutoARIMA в Python (англ.).

Совсем дополнительное чтение:

<https://faculty.washington.edu/ezivot/econ584/notes/unitroot.pdf> — подробное описание и проблемы тестов на стационарность (англ.).